

Relatório técnico

Classificação de risco de câncer de mama com Machine Learning

Estudo educacional de apoio à triagem clínica a partir do Breast Cancer Wisconsin Diagnostic Dataset. O modelo não produz diagnóstico e não substitui a decisão de profissionais de saúde.

GRUPO

Grupo 20

AUTOR

Rafael Neves de Oliveira

RM

371255

E-MAIL

rafaelneves652@gmail.com

1. Entrega e organização do repositório

Este PDF reúne o relatório técnico e o mapa dos artefatos exigidos na Fase 1. O código-fonte, o README, o dataset local e os gráficos reproduzíveis ficam no repositório do projeto.

Item exigido	Onde está
Link do repositório Git	Ainda não há remoto publicado. Após o <code>git push</code> , substitua este campo pela URL pública (GitHub/GitLab).
Código-fonte completo	<code>src/iadt_ml/</code> , com testes em <code>tests/</code> e empacotamento em <code>pyproject.toml</code> .
README com instruções de execução	<code>README.md</code> na raiz. Resumo operacional na seção 9 deste relatório.
Dockerfile	Não aplicável nesta fase. A execução usa ambiente virtual Python, sem container.
Dataset (ou link para download)	Arquivo local <code>data/raw/breast_cancer.csv</code> . Fonte pública: Breast Cancer Wisconsin Diagnostic Dataset .
Resultados (prints, gráficos e análises)	<code>reports/figures/</code> , reproduzidos e interpretados nas seções 4, 6 e 7.
Relatório técnico	Este documento e a versão em Markdown em <code>reports/technical_report.md</code> .

1.1 Estrutura do código

O projeto segue Clean Architecture. As regras de negócio não dependem de pandas, scikit-learn ou da CLI. Isso permite trocar a interface ou a persistência sem reescrever a seleção do modelo.

<code>src/iadt_ml/</code>	
<code> domain/</code>	entidades e contratos
<code> application/</code>	casos de uso (analisar, treinar, explicar)
<code> infrastructure/</code>	CSV, scikit-learn, joblib, gráficos e SHAP
<code> presentation/</code>	CLI <code>iadt-ml</code>
<code>data/raw/</code>	dataset local (não versionado)
<code>models/</code>	pipeline serializado
<code>reports/figures/</code>	gráficos e tabelas da execução
<code>tests/</code>	testes unitários e de integração

Fluxo interno: CLI → caso de uso → porta do domínio → adaptador de infraestrutura. O comando de treino, por exemplo, executa carga do CSV, divisão estratificada, validação cruzada, seleção por recall, avaliação única no teste e persistência do pipeline vencedor.

2. Problema e objetivo

O sistema classifica registros de exames de câncer de mama como benignos (B) ou malignos (M) para apoiar a triagem. O resultado é uma estimativa estatística aprendida em dados históricos. Não é diagnóstico clínico e não substitui a conduta de médicos ou médicas.

Em saúde, deixar de sinalizar um caso maligno pode atrasar a investigação. Por isso, a métrica prioritária de seleção é o **recall da classe maligna**. F1-score e accuracy entram apenas como critérios de

desempate.

Banco vetorial não foi utilizado. A entrada é tabular e o problema é classificação supervisionada. Busca semântica seria uma extensão futura para prontuários textuais, não para este pipeline.

3. Dados

Foi utilizado o **Breast Cancer Wisconsin Diagnostic Dataset**, indicado no enunciado. A base contém 569 registros e 30 atributos numéricos extraídos de imagens digitalizadas de aspiração por agulha fina (FNA), além da variável-alvo `diagnosis`.

Cada núcleo celular é descrito por dez medidas (raio, textura, perímetro, área, suavidade, compacidade, concavidade, pontos côncavos, simetria e dimensão fractal), nas versões média (`_mean`), erro padrão (`_se`) e pior valor (`_worst`).

569

registros após a carga validada

30

atributos numéricos preditores

357 / 212

benignos / malignos

0

valores ausentes e linhas duplicadas

Link para download: <https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data>. O arquivo `data.csv` deve ser salvo como `data/raw/breast_cancer.csv`. O CSV bruto não é versionado no Git, por política de não publicar dados externos sem necessidade.

4. Discussão da análise exploratória

A análise exploratória antecede o treino. Ela descreve o balanceamento das classes, a escala das variáveis, a sobreposição entre diagnósticos e a redundância linear entre medidas geométricas. Os artefatos foram gerados pelo comando `iadt-ml analyze` e gravados em `reports/figures/`.

4.1 Distribuição das classes

Há 357 registros benignos (62,7%) e 212 malignos (37,3%). O desbalanceamento é moderado, não extremo. Ainda assim, accuracy isolada seria enganosa: um classificador que previsse apenas benigno acertaria cerca de 63% dos casos e falharia precisamente na classe que importa para a triagem. Por isso a validação e a seleção usam recall da classe `M`, com divisão estratificada para preservar a proporção em treino e teste.




Figura 1. Distribuição da variável diagnosis: 357 benignos e 212 malignos.

4.2 Escala, forma e poder discriminativo

As escalas diferem bastante. `area_mean` varia de 143,5 a 2.501, enquanto `smoothness_mean` permanece entre 0,05 e 0,16. Modelos lineares com regularização implícita na solução, como a Regressão Logística, precisam de padronização para que a magnitude da unidade não domine o coeficiente.

Os histogramas por classe mostram que medidas de tamanho e irregularidade separam melhor benigno e maligno: `radius_mean`, `perimeter_mean`, `area_mean`, `concave points_mean` e os equivalentes `_worst` deslocam a massa da classe maligna para valores mais altos. Já `smoothness_mean`, `symmetry_mean`, `fractal_dimension_mean` e a maior parte dos atributos `_se` apresentam forte sobreposição. A assimetria à direita é frequente, o que reforça imputação por mediana em vez de média caso surjam ausências futuras.




Figura 2. Densidade de cada atributo segundo o diagnóstico. Azul: maligno. Laranja: benigno.

4.3 Correlação e redundância

Não há variáveis categóricas a codificar neste recorte: todos os preditores já são numéricos. A matriz de correlação, porém, revela multicolinearidade estrutural. Raio, perímetro e área descrevem a mesma geometria do núcleo. A correlação entre `radius_mean` e `perimeter_mean` é aproximadamente **0,998**; entre `radius_mean` e `area_mean`, cerca de **0,987**. Médias e piores valores da mesma medida também caminham juntas (`radius_mean` e `radius_worst` $\approx$ 0,970).

Há um segundo bloco correlacionado em irregularidade: `compactness`, `concavity` e `concave points`. Essa redundância não invalida os modelos escolhidos, mas impede ler cada coeficiente da Regressão Logística como efeito isolado e independente. A Random Forest tolera melhor colinearidade, porém também não transforma correlação em causalidade clínica.




Figura 3. Correlação de Pearson entre os 30 atributos. Blocos escuros indicam redundância geométrica.

4.4 Qualidade da base

Na versão utilizada não há valores ausentes nem linhas duplicadas. O identificador `id` e a coluna vazia auxiliar (`Unnamed: 32`) existem no CSV original e são removidos na carga, porque não descrevem o exame. Qualidade boa da base pública não equivale a representatividade da população de um hospital específico.

Artefato da EDA	Arquivo
Estatísticas descritivas	<code>descriptive_statistics.csv</code>
Resumo da carga	<code>exploratory_summary.json</code>
Distribuição das classes	<code>class_distribution.png</code>
Distribuições por atributo	<code>feature_distributions.png</code>
Mapa de correlação	<code>correlation_heatmap.png</code>
Tabela de correlações	<code>feature_correlations.csv</code>

5. Estratégias de pré-processamento

O pré-processamento pertence ao `Pipeline` do scikit-learn e é ajustado somente com o conjunto de treino. O conjunto de teste nunca participa do cálculo de mediana ou de escala. Isso evita vazamento de informação, equivalente a estudar com o gabarito da prova.

Remoção de identificadores

`id` e colunas auxiliares vazias saem na leitura. Identificadores podem criar atalhos sem valor clínico e não devem entrar no modelo.

Conversão numérica

Todos os preditores são convertidos para número. Células ilegíveis viram ausências (`NaN`) e só então passam pelo imputador do pipeline.

Divisão estratificada

80% treino e 20% teste, com semente fixa 42. A estratificação preserva a proporção B/M. Na execução atual isso resulta em cerca de 455 registros de treino e 114 de teste.

Imputação pela mediana

Ambos os modelos usam `SimpleImputer(strategy="median")`. A mediana é mais estável que a média na presença de caudas longas, observadas na EDA. Na base atual não há ausências, mas o passo permanece para tornar o pipeline robusto a dados futuros incompletos.

Padronização apenas na Regressão Logística

A Regressão Logística recebe `StandardScaler` depois da imputação. Sem isso, variáveis como área dominariam variáveis como suavidade. A Random Forest não usa scaler: partições por limiar são invariantes a transformações monotônicas de escala.

Validação cruzada só no treino

Três dobras estratificadas no treino comparam os candidatos. O teste permanece isolado até a avaliação final única do modelo já escolhido.

Etapa	Regressão Logística	Random Forest
Remoção de <code>id</code>	Sim	Sim
Imputação (mediana)	Sim	Sim
Padronização	Sim	Não
Ajuste do transformador	Somente treino	Somente treino

6. Modelos usados e por quê

Foram comparados dois classificadores supervisionados, suficientes para a Fase 1 e complementares em hipótese estatística: um linear interpretável e um conjunto não linear.

6.1 Regressão Logística

Baseline linear, estável e relativamente simples de interpretar. Estima a probabilidade de malignidade a partir de uma combinação ponderada dos atributos padronizados. Foi escolhida porque:

- oferece um ponto de partida honesto, sem hiperparametrização agressiva;
- lida bem com dados tabulares contínuos de dimensionalidade moderada;
- produz probabilidades úteis para ROC-AUC;
- é rápida de treinar e de explicar em um relatório acadêmico.

Configuração: `max_iter=2000`, `random_state=42`, pipeline com imputação e scaler. Não se espera que capture interações complexas sem engenharia extra.

6.2 Random Forest

Conjunto de 400 árvores de decisão. Cada árvore vê uma amostra e um subconjunto de atributos; a floresta agrega os votos. Foi incluída porque:

- modela relações não lineares e interações entre medidas;
- é pouco sensível à escala, o que dispensa padronização;
- tolera melhor colinearidade do que um modelo linear puro;
- serve de contraste: se ganhasse de forma clara, a hipótese linear seria insuficiente.

6.3 Protocolo de escolha

Dentro do treino, cada candidato passa por validação cruzada estratificada de três dobras. A seleção usa, nesta ordem: maior recall de malignidade, maior F1-score, maior accuracy. O vencedor é reajustado em todo o treino e só então avaliado no teste.

Modelo	Accuracy (CV)	Recall (CV)	F1 (CV)
Regressão Logística	0,974	0,959	0,965
Random Forest	0,956	0,935	0,941

A Regressão Logística venceu em recall, F1 e accuracy de validação. A hipótese linear, com atributos já bastante discriminativos na EDA, foi suficiente neste recorte. A Random Forest não foi descartada por ser “pior em absoluto”: ela permanece documentada como alternativa, mas não justificava a complexidade extra na métrica prioritária.

7. Resultados e interpretação

A avaliação final usou 114 registros isolados. Esses exemplos não participaram da escolha do algoritmo nem do ajuste dos transformadores, além do que o pipeline aplica na transformação já aprendida no treino.

7.1 Métricas no teste

Métrica	Resultado	Leitura
Accuracy	0,965	110 acertos em 114 registros.
Recall de malignidade	0,929	39 de 42 malignos foram sinalizados.
F1-score de malignidade	0,951	Equilíbrio entre identificar malignos e não inflar alarmes.
ROC-AUC	0,996	Forte capacidade de ordenar as duas classes por probabilidade.

7.2 Matriz de confusão

Classe real / prevista	Benigno	Maligno
Benigno	71	1
Maligno	3	39




Figura 4. Matriz de confusão da Regressão Logística no teste (n = 114).

Houve 1 falso positivo e 3 falsos negativos. O falso positivo gera investigação extra, custo aceitável em triagem. Os três falsos negativos são o ponto crítico: casos malignos que o modelo tratou como benignos. Recall de 0,929 é alto para um exercício acadêmico, mas esses três erros bastam para afirmar que o sistema não pode decidir sozinho.

O ROC-AUC próximo de 1 indica boa ordenação das probabilidades, não ausência de erro no limiar padrão 0,5. Um uso real poderia recalibrar o limiar para reduzir falsos negativos, à custa de mais falsos positivos —

decisão clínica e operacional, não apenas estatística.

8. Explicabilidade

Depois da avaliação, o comando `iadt-ml explain` descreve o modelo já escolhido. Essa etapa não retreina nem troca o algoritmo.

8.1 Importância por permutação

A técnica embaralha um atributo por vez no teste e mede a queda do recall. Se o desempenho cai, aquele atributo era útil para identificar malignidade. Na execução atual destacaram-se `texture_worst`, `concavity_worst`, `symmetry_worst` e `concave points_worst`.

Valores próximos de zero ou negativos não provam que a variável “faz mal” na natureza: com 114 linhas e atributos colineares, a permutação de um preditor redundante pode até parecer neutra. A leitura correta é relativa: textura e irregularidade no pior valor pesaram mais para o recall do que medidas de erro padrão isoladas.




Figura 5. Importância por permutação: redução média do recall ao embaralhar cada atributo.

8.2 SHAP

SHAP resume a contribuição média absoluta de cada atributo para a saída do classificador.

`texture_worst` aparece novamente no topo, seguida de atributos de simetria, tamanho e pontos côncavos. A convergência entre permutação e SHAP aumenta a confiança de que a textura no pior valor e marcas de irregularidade guiam o modelo.




Figura 6. Importância global SHAP (média do valor absoluto) no modelo selecionado.

SHAP e importância por permutação explicam o comportamento matemático do classificador. Não demonstram relação causal entre uma característica celular e a doença, nem autorizam conduta clínica sem revisão humana.

9. Como executar

Não há Dockerfile nesta fase. O ambiente recomendado é um virtualenv com Python 3.11 ou superior.

```
python3 -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
python -m pip install -e '.[dev]'

# dataset: data/raw/breast_cancer.csv
iadt-ml analyze --dataset data/raw/breast_cancer.csv
iadt-ml train --dataset data/raw/breast_cancer.csv
iadt-ml explain --dataset data/raw/breast_cancer.csv --model models/best_model.joblib

pytest
ruff check .
```

Os gráficos saem em `reports/figures/`. O pipeline vencedor é salvo em `models/best_model.joblib` e inclui imputação e scaler, não apenas o classificador.

10. Discussão crítica e responsabilidade

O desempenho é promissor para um exercício acadêmico com base clássica e bem estudada. Ele não comprova adequação a ambiente hospitalar. Limitações principais:

- base pública, histórica e pequena (569 registros);
- origem específica (Wisconsin), sem garantia de calibre para outra população;
- ausência de contexto clínico completo, histórico familiar, exames complementares e variáveis sociodemográficas;
- multicolinearidade, que dificulta atribuir importância isolada a cada medida;
- três falsos negativos no teste, inaceitáveis como decisão autônoma;
- falta de validação externa em outra instituição e de monitoramento temporal de drift.

Um uso real exigiria validação clínica formal, avaliação de viés, controle de versão de dados e modelos, governança de acesso, conformidade com a LGPD e decisão final de profissional habilitado. Este trabalho permanece no escopo educacional de apoio à triagem.

11. Referências de dados e artefatos

- UCI / Kaggle. Breast Cancer Wisconsin (Diagnostic) Data Set.
<https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data>
- Wolberg, W., Street, W. N., Mangasarian, O. Breast Cancer Wisconsin (Diagnostic).
- Código e testes deste projeto: diretório `src/iadt_ml` e `tests`.
- README operacional: `README.md`.
- Figuras e tabelas: `reports/figures/`.